Modelagem Preditiva da Severidade de Sinistros

Davi Ferrari Hannickel - 15447480
Henrique Nardi Farbelow - 15459250

SME0823 - Modelos de Regressão e Aprendizado Supervisionado II
Setembro de 2026

Introdução e Contextualização

O objetivo deste trabalho é aplicar os conhecimentos obtidos em aula em uma modelagem estatística para severidade de sinistros automotivos passando por todas as etapas da análise, desde a compreensão da base de dados até os métodos de validação e as conclusões obtidas.

Os dados são provenientes da base `AutoClaims` do pacote `insuranceData`. Os dados e as análises a seguir estão disponíveis no repositório:

https://github.com/hnfarbelow/Regress-o-para-a-Severidade-de-Sinistros/blob/main/CÃ§digos_reg_II.ipynb

Parte A: Compreensão e Preparação dos Dados

A base de dados analisada é composta por $n = 6.773$ observações e 5 variáveis: `STATE`, `CLASS`, `GENDER`, `AGE` e `PAID`. A população de interese consiste no valor pago para liquidar e encerrar um sinistro em uma seguradora de automóveis do meio-oeste dos Estados Unidos.

A1. Variáveis do Modelo

A unidade observacional é o acontecimento de um sinistro, as variáveis envonvem informações sobre o condutor e o veículo:

- **Variáveis Preditoras**
  - `STATE`: Variável categórica nominal que indica o estado ou região geográfica de origem do sinistro reportado;
  - `CLASS`: Variável categórica que indica a classe de risco associada a apólice contratada. Agrupa riscos com características semelhantes;
  - `GENDER`: Variável categórica binária que identifica o gênero do condutor;
  - `AGE`: Variável quantitativa contínua que representa a idade do segurado em anos;
- **Variável Resposta**
  - `PAID`: Variável resposta contínua e estritamente positiva (Y) pois expressa o valor financeiro total pago pela seguradora para a liquidação do sinistro.

A2. Tratamento de Categorias Raras e Agrupamento

Foi realizada uma verificação na base buscando valores ausentes e sem sentido (fora do suporte e/ou incondizente com a realidade), foi delimitado o intervalo aceitável para a idade como sendo entre 18 e 100 anos.

Tabela 1: Resumo da verificação de integridade e consistência dos dados.

Critério	**Alvo**	**Qtd. (N)**	**Percentual**
Valores Ausentes	Todas as variáveis	0	0,00%
Pagamentos Não Positivos	Variável `PAID` (≤ 0)	0	0,00%
Idades Implausíveis	Variável `AGE` (< 18 ou > 100)	0	0,00%
Categoria Rara (Limiar $< 0,5\%$)	`STATE 11`	9	0,133%
Categoria Rara (Limiar $< 0,5\%$)	`CLASS F1`	29	0,428%

A Tabela 1 mostra que não existem valores ausentes e nem valores incoerentes em nenhuma categoria. A existência de categorias raras pode aumentar a complexidade do modelo sem necessidade e piorar a estimação, uma possibilidade seria remove-las, mas a princípio iremos seguir com elas na análise.

A3. Amostra Analítica

A amostra analítica que será utilizada é a própria base dados completa com $n = 6.773$ observações. Não será feita a remoção de nenhuma observação pois não foi encontrada nenhuma inconsistência nos dados. Vale destacar que, como citada acima, é importante estudar um possível impacto prejudicial à estimação das categorias raras apresentadas.

A4. Identificação das Variáveis Categóricas

Para as três variáveis categóricas será escolhida a categoria com maior frequência como referência, isso ajuda a melhorar a estimação pois diminui a variabilidade dos parâmetros das variáveis *dummy*. São elas:

Tabela 2: Resumo das variáveis categóricas

Variável	Número de categorias	Categoria mais frequente	% da amostra
`STATE`	13	`STATE 15`	32,19%
`CLASS`	18	`C11`	16,99%
`GENDER`	2	`M`	61,88%

Parte B: Análise Exploratória

B1. Medidas Descritivas da Variável Resposta

Tabela 3: Medidas descritivas (`PAID`).

Medida	Valor
Mínimo	9,50
Q_1	523,73
Mediana (Q_2)	1.001,70
Média	1.853,03
Q_3	2.137,40
Máximo	60.000,00
Desvio-Padrão	2.646,91
Coeficiente de Variação (CV %)	142,84%
Assimetria	6,24

Pela Tabela 3, é possível notar que a variável possui uma alta assimetria, tanto pelo coeficiente de assimetria quanto pela distância entre a mediana e a média. Esse comportamento é esperado, pois é mais comum a ocorrência de sinistros de valor baixo (batidas leves e arranhões) em relação a sinistros de alto custo, entretanto, os eventos mais severos tendem a atingir valores muito elevados (colisões muito fortes e perda total), gerando uma forte assimetria positiva nos dados. Nessa mesma lógica, vemos que a variabilidade da variável também é extremamente alta ($CV > 100\%$).

B2. Distribuição Amostral da Variável Resposta

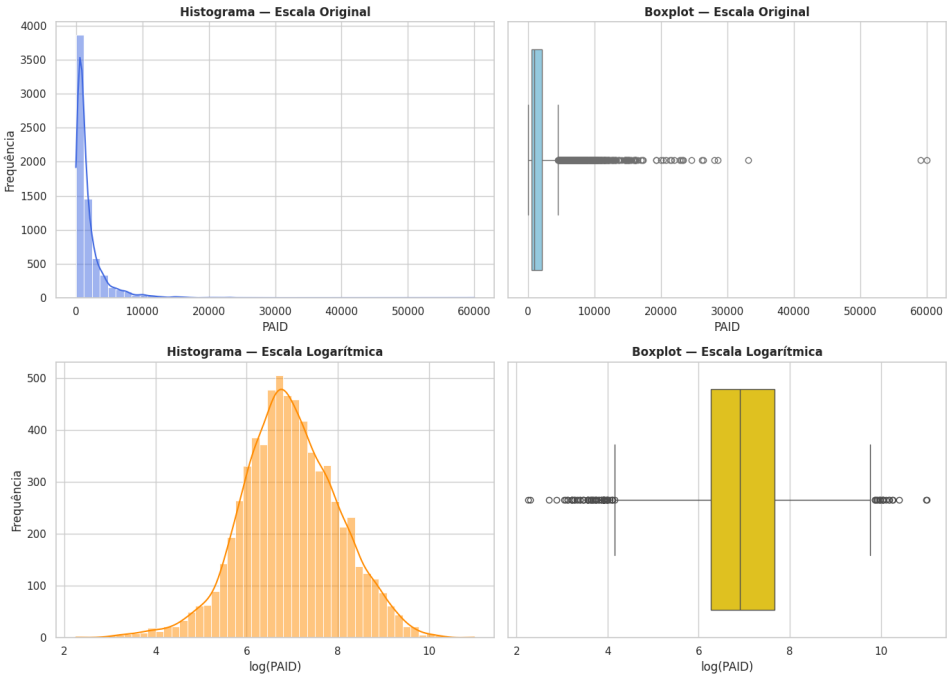


Figura 1: Histogramas e Boxplots em escala normal e logarítimica da variável resposta

A Figura 1 revela que na escala normal os dados são altamente assimétricos e todos os outliers estão à direita da região mais densa. Quando analisamos a distribuição em escala logarítmica, vemos que a assimetria diminui drasticamente e a distribuição se aproxima de um comportamento mais simétrico (próximo à normalidade), com outliers em ambos os extremos. Essa melhora significativa na simetria ao aplicar o log é um forte indicativo de que a função de ligação logarítmica é a mais adequada para o estudo de regressão.

B3. Estudo da Relação entre `PAID` e `AGE`

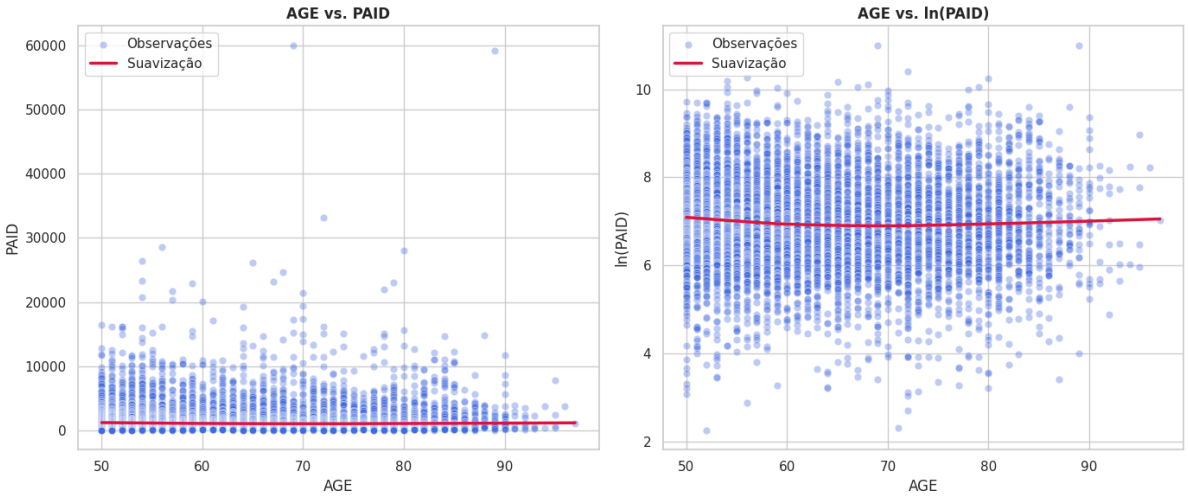


Figura 2: `AGE` vs. `PAID` em diferentes escalas

A imagem 2 evidencia que a relação entre `AGE` e `PAID` é linear, entretanto o coeficiente angular é muito próximo de zero, ou seja, a variável `AGE`, isoladamente, apresenta um poder preditivo linear fraco. A variabilidade entre elas é parecida ao longo de todas as idades da amostra, com alguns *outliers*. Vale destacar que é possível que a variável `AGE` possa ter um poder preditivo maior quando combinada com as outras variáveis do modelo

B4. Estudo da Relação entre `GENDER` e `STATE` com `PAID`

Como a variável `PAID` é muito assimétrica, os gráficos a seguir foram feitos em escala logarítmica.

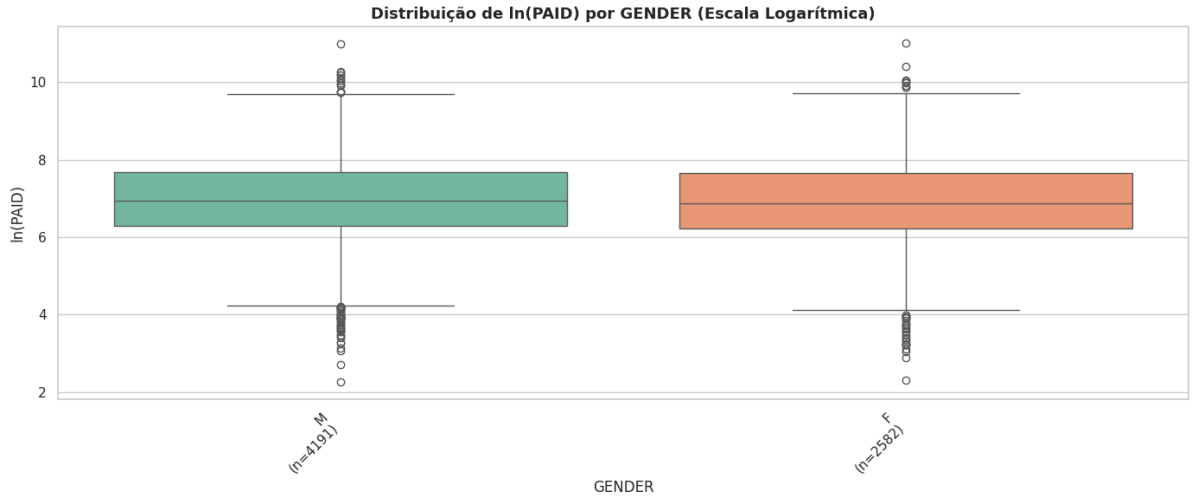


Figura 3: Boxplot `GENDER` vs. `PAID`

Como já apresentado anteriormente, o número de homens na amostra representa cerca 61% da amostra. Ambas categorias tem distribuição muito próxima, com uma variância alta e com muitos *outliers*, então podemos dizer que a varaiável `GENDER`, isoladamente, tem um poder preditivo baixo.

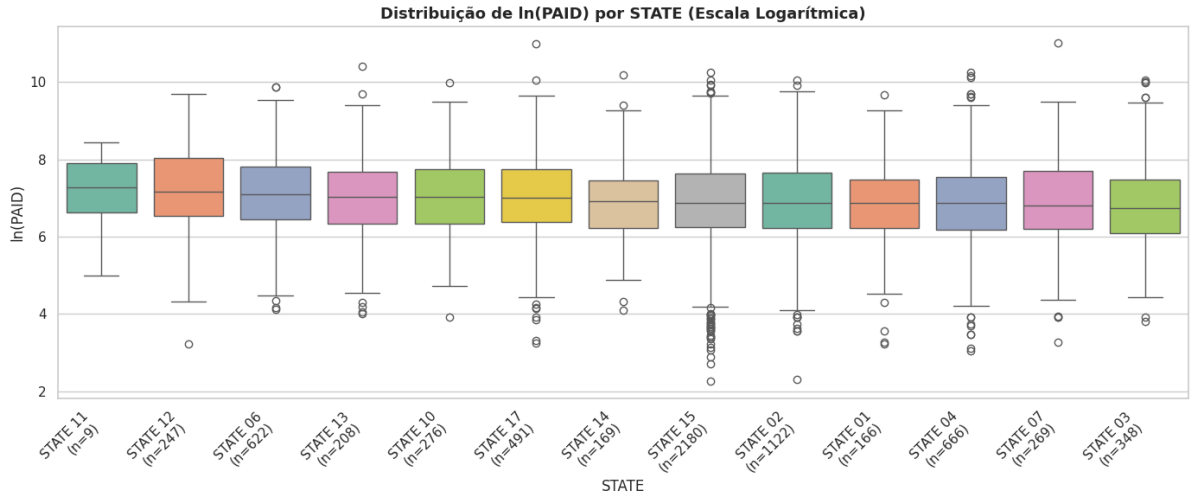


Figura 4: Boxplot `STATE` vs. `PAID`

A variável `STATE` possui 13 categorias e tem uma alta variabilidade dentro delas, entretanto,

assim como `GENDER` a variabilidade entre as categorias não é muito alta, diminuindo o poder preditivo da variável (isoladamente). É importante ressaltar que existem grupos com baixa representatividade (poucas observações), assim os valores calculados nestes grupos tem uma maior incerteza associada.

B5. Estudo da variável `CLASS`

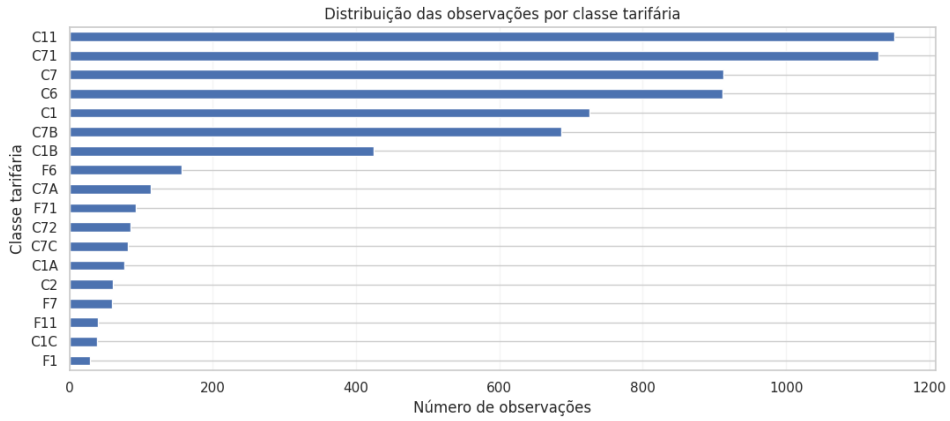


Figura 5: Frequências da Variável `CLASS`

A imagem 5 indica com clareza que existem classes que possuem um número baixo de observações, essas classes podem prejudicar o ajuste pois as informações sobre elas são escassas, isso aumenta a variabilidade e piora a estimação. Existem formas de contornar isso como excluir essas classes ou uni-las a uma classe similar.

Parte C: Formulação do Modelo

Está seção apresentará diferentes formas de formular a regressão.

C1. Componente Aleátoria do Modelo

1. Modelo Normal

$$Y_i \mid x_i \sim \text{Normal}(\mu_i, \sigma^2)$$

- Média condicional: $\mathbb{E}(Y_i \mid x_i) = \mu_i$
- Função de ligação: $\eta_i = \ln(\mu_i)$
- Função de variância: $V(\mu_i) = 1$, de modo que $\text{Var}(Y_i \mid x_i) = \phi$, onde o parâmetro de dispersão é $\phi = \sigma^2$.

2. Modelo Gama

$$Y_i \mid x_i \sim \text{Gamma}(\alpha, \beta_i)$$

- Média condicional: $\mathbb{E}(Y_i \mid x_i) = \mu_i = \alpha/\beta_i$
- Função de ligação: $\eta_i = \ln(\mu_i)$
- Função de variância: $V(\mu_i) = \mu_i^2$, de modo que $\text{Var}(Y_i \mid x_i) = \phi\mu_i^2$, onde o parâmetro de dispersão é $\phi = 1/\alpha$.

3. Modelo Gaussiano Inverso

$$Y_i \mid x_i \sim \text{InvGauss}(\mu_i, \lambda)$$

- Média condicional: $\mathbb{E}(Y_i \mid x_i) = \mu_i$
- Função de ligação: $\eta_i = \ln(\mu_i)$
- Função de variância: $V(\mu_i) = \mu_i^3$, de modo que $\text{Var}(Y_i \mid x_i) = \phi\mu_i^3$, onde o parâmetro de dispersão é $\phi = 1/\lambda$.

C2. Função de Ligação

Ao comparar diferentes componentes aleatórios é nescessário utilizar a mesma função de ligação para garantir que a diferença de desempenho seja exclusivamente devido à escolha das distribuições. Isso se reflete na função de variância do modelo, ou seja, o modelo em que a variabilidade mais se adeque aos dados será o melhor:

$$V_{\text{norm}}(\mu_i) \propto 1 \qquad V_{\text{gamma}}(\mu_i) \propto \mu_i^2 \qquad V_{\text{inv}}(\mu_i) \propto \mu_i^3$$

C3. Estruturas Candidatas

$$\begin{aligned}
M_0 &: \eta_i = \beta_0 \\
M_1 &: \eta_i = \beta_0 + \beta_1 \text{AGE}_{c,i} + \text{GENDER}_i \\
M_2 &: \eta_i = \beta_0 + \beta_1 \text{AGE}_{c,i} + \text{GENDER}_i + \text{STATE}_i \\
M_3 &: \eta_i = \beta_0 + \text{CLASS}_i + \text{STATE}_i \\
M_4 &: \eta_i = \beta_0 + \beta_1 \text{AGE}_{c,i} + \text{GENDER}_i + \text{CLASS}_i + \text{STATE}_i
\end{aligned}$$

Em que $\text{AGE}_{c,i} = \text{AGE}_i - \overline{\text{AGE}}$ representa a idade centralizada em relação à média amostral, na amostra $\overline{\text{AGE}} = 63.8115$. A vantagem dessa abordagem é que em vez de representar o valor esperado de um indivíduo com idade igual a zero, o intercepto passa a representar o valor esperado de um indivíduo com a idade igual a média amostral.

É importante ressaltar que as variáveis categóricas serão modeladas usando váriaveis *dummy*.

C4. Interpretação da Função de Ligação

- $\exp(\beta_1)$: É o fator pelo qual a variável resposta é multiplicada para cada acréscimo de uma unidade no valor da idade centralizada, mantendo as demais variáveis constantes.
- $\exp(\beta_j)$: É o fator pelo qual a variável resposta é multiplicada quando se transita da categoria de referência para a categoria correspondente da variável *dummy*, mantendo as demais variáveis constantes.
- $100(\exp(\beta_j) - 1)\%$: Representa o percentual de aumento (ou redução) esperado na variável resposta para aquela categoria específica em comparação à categoria de referência.

C5. Análise da Estrutura M_4

O modelo M_4, que inclui simultaneamente todas as covariáveis, pode apresentar problemas de redundância e uma alta multicolinearidade. Isso acontece pois a variável `CLASS` provavelmente foi construída pela empresa com base em fatores geográficos (`STATE`) e socias (`GENDER` e `AGE`).

Para avaliar formalmente essa hipótese podemos usar testes como o Teste da Razão de Verossimilhanças. Especificamente, comparando o modelo completo M_4 com o modelo reduzido M_3, testando a hipótese nula de que os coeficientes associados à idade e ao gênero são simultaneamente iguais a zero.

Parte D: Ajuste, Inferência e Seleção

D1. Ajustando o modelo M_1

O primeiro modelo a ser ajustado será o M_1. É eperado que seja um modelo que equilíbra complexidade e poder preditivo. Não houveram problemas de convergência no modelo.

D2. Resultados do Primeiro Ajuste

Tabela 4: Estimativas e estatísticas dos modelos ajustados (M_1)

Modelo	Termo	Estimativa	Erro Padrão	IC 95% Inf.	IC 95% Sup.	p-valor
Normal	Intercepto	7,5212	0,0221	7,4778	7,5646	0,0000
	GENDER	0,0089	0,0357	-0,0610	0,0788	0,8027
	AGEc	0,0006	0,0016	-0,0026	0,0038	0,7191
Gama	Intercepto	7,5211	0,0220	7,4779	7,5643	0,0000
	GENDER	0,0090	0,0357	-0,0610	0,0789	0,8011
	AGEc	0,0005	0,0016	-0,0027	0,0037	0,7452
Gaussiano Inv.	Intercepto	7,5211	0,0220	7,4780	7,5642	0,0000
	GENDER	0,0090	0,0357	-0,0610	0,0790	0,8006
	AGEc	0,0005	0,0016	-0,0027	0,0037	0,7566

D3. Interpretação do Primeiro Ajuste

- Efeito da idade (AGE_c): Como a estimativa é próxima de $0,0005$ e o p-valor é elevado ($\approx 0,75$), o efeito da idade no valor pago para liquidar o sinistro não é significativo. Cada ano adicional multiplica valor pago esperado por $e^{0,0005} \approx 1,0005$ (variação de $0,05\%$).
- Efeito do gênero (GENDER): O coeficiente da variável *dummy* apresenta p-valor em torno de $0,80$, indicando que o efeito do gênero no valor pago para liquidar o sinistro não é significativo . O fator multiplicativo associado é de $e^{0,0090} \approx 1,009$ (cerca de $0,9\%$ de diferença).
- Contraste entre classes ou estados (CLASS / STATE): Como o modelo inicial (M_1) considera apenas idade e gênero, os efeitos de classes tarifárias ou estados não foram estimados. Entretanto, conceitualmente, o contraste entre categorias corresponderia à exponencial do respectivo coeficiente, representando a razão entre os pagamentos médios esperados:

$$\frac{\mu_{\text{cat}}}{\mu_{\text{ref}}} = \frac{\exp(\beta_0) \cdot \exp(\beta_j)}{\exp(\beta_0)} = \exp(\beta_j)$$

D4. Comparação entre as Distribuições Propostas

Tabela 5: Comparação de Desempenho entre as Famílias de Modelos

Modelo	Log-Verossimilhança	AIC	BIC	Delta_AIC	Peso de Akaike
Gaussiano Inverso	-57658,8211	115323,6421	115344,1042	0,0000	$\approx 1,0$
Gama	-58688,4115	117382,8231	117403,2852	2059,1810	$\approx 0,0$
Normal	-62988,8921	125983,7842	126004,2463	10660,1421	$\approx 0,0$

A tabela 5 indica que o modelo Gaussiano Inverso é substancialmente superior aos outros concorrentes sob a estrutura M_1.

D5. Ajuste das Outras Estruturas sob o Modelo Gaussiano Inverso

Foram ajustados os modelos M_1, M_2, M_3 e M_4 considerando o modelo Gaussiano Inverso.

Tabela 6: Comparação de Desempenho entre as Estruturas de Modelos

Modelo	Log-Verossimilhança	AIC	BIC	Delta_AIC	Peso de Akaike
M1	-57658,8211	115323,6421	115344,1042	0,0000	0,8283
M2	-57648,4051	115326,8103	115429,1208	3,1681	0,1699
M3	-57637,9945	115335,9889	115540,6099	12,3468	0,0017
M4	-57640,8427	115345,6854	115563,9478	22,0433	0,0000

M_1 é o modelo mais simples e fácil de interpretar, pois na prática ele diz que o valor esperado que será pago para liquidar o sinistro é simplesmente $\exp(\beta_0)$, como esse modelo também obteve os menores valores de AIC e BIC podemos dizer que ele é o mais adequado.

Outro fator notável é que a inclusão da variável `CLASS` (presente em M_3 e M_4) penaliza fortemente o desempenho devido ao elevado número de categorias diferentes. O fato discutido anteriormente sobre a redundância devido a sua construção também prejudica o desempenho do modelo.

Para testar se a inclusão das variáveis adicionais em M_4 traz um ganho significativo em relação a M_3 como proposto em C5 usamos:

$$\Lambda = -2 \cdot (\log L_{M4} - \log L_{M3}) \approx 5,6964$$

Que resulta em um p-valor $\approx 0,058$ ($P(\chi^2_2 \geq 5,6964)$, não rejeitando H_0 a 5% de significância, não existem evidências de que a diferença de ajuste entre as duas estruturas é estatisticamente significativa.

D6. Procedimento Automático de Seleção

O estudo foi realizado comparando os modelos com base nos critérios de informação e no princípio da parcimônia, o procedimento automático de seleção de variáveis não chegou a ser realizado.

Parte E: Análise Residual e Influência

E1. Resíduos de Pearson

Abaixo são apresentados os gráficos dos resíduos de Pearson contra a idade e contra os valores ajustados, bem como os gráficos quantil-quantil (QQ-plots) dos resíduos de desvio padronizados para as famílias Normal, Gama e Gaussiano Inverso.

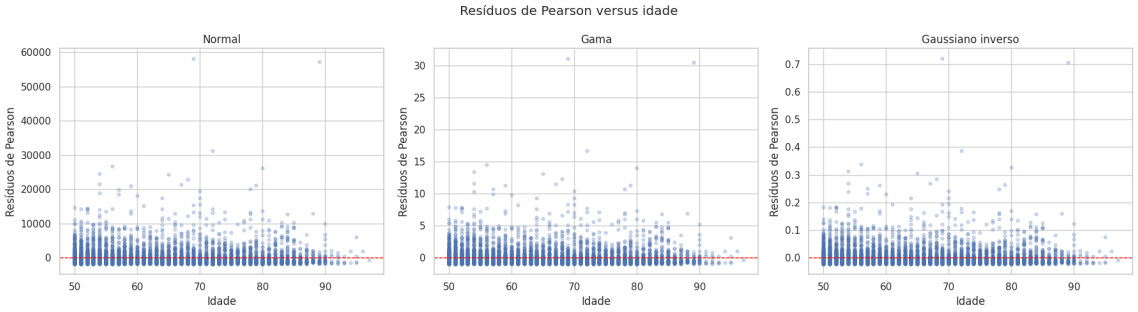


Figura 6: Resíduos de Pearson versus Idade para as três famílias.

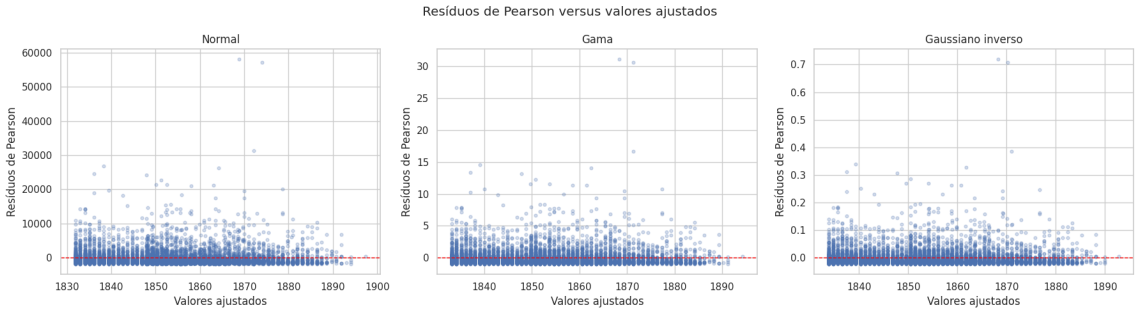


Figura 7: Resíduos de Pearson versus Valores Ajustados para as três famílias.

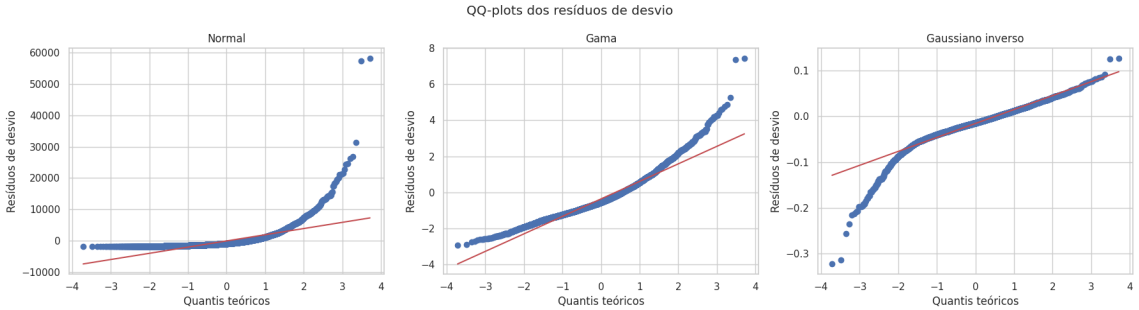


Figura 8: QQ-plots dos resíduos de desvio para as três famílias.

Os gráficos de dispersão apresentam um comportamento semelhante nas três famílias. O QQ-plot indica uma superioridade da distribuição Gaussiana Inversa, uma vez que a tendência central dos resíduos acompanha mais de perto a linha teórica. No entanto, existe um distanciamento alto nos quantis iniciais (cauda inferior). Esse tipo de comportamento é esperado em dados altamente assimétricos onde o ajuste nas fronteiras da distribuição se torna mais difícil.

E2. Impacto da Função de Variância

Tabela 7: Resumo das Médias e Desvios Padrão dos Resíduos

Modelo	Média Pearson	DP Pearson	Média Dev. Pad.	DP Dev. Pad.
Normal	0,0017	2646,8726	0,0088	2647,5187
Gama	-0,0000	1,4261	-0,3652	1,0026
Gaussiano inverso	0,0000	0,0331	-0,0156	0,0317

A análise das médias e desvios padrão dos resíduos confirma a instabilidade da distribuição Normal, cujos desvios padrão atingem valores extremos. Em contrapartida, a família Gama consegue reduzir essa dispersão, e o modelo Gaussiano Inverso tem o comportamento mais estável de todos, com um desvio padrão em torno de $0,033$ (*Pearson*) e $0,0317$ (*Deviance* Padronizado). Isso reafirma que a função de variância da Gaussiana Inversa é a que melhor se adequa os dados.

E3. Observações Problemáticas

Os critérios adotados considerando $n = 6773$ e $p = 3$ sob a estrutura M_1 são:

$$|r_i| > 2, \qquad h_{ii} > 2p/n = 0.00088, \qquad D_i > 4/n = 0.000591$$

Estes limiares são usados como referências heurísticas de diagnóstico, e não são testes estatísticos formais, servindo para sinalizar pontos que merecem atenção na estrutura dos dados.

Tabela 8: Contagem de Observações Problemáticas por Critério e Família

Modelo	$\|r_i\| > 2$	$h_{ii} > 2p/n$	$D_i > 4/n$	≥ 2 Critérios	Os 3 Critérios
Normal	6770	234	263	481	16
Gama	303	208	263	194	9
Gaussiano inverso	0	208	262	16	0

A aplicação destes critérios aos modelos ajustados revela que a distribuição Normal é a mais problemática, enquanto, o modelo Gaussiano Inverso demonstra uma estabilidade alta, vale destacar ela não possui nenhuma observação fora do padrão adotado no quesito resíduo padronizado.

E4. Observações extremas

Tabela 9: Resultados detalhados das observações extremas

Índice	PAID	AGE	GENDER	STATE	CLASS	Resíduo	h_{ii}	D_i
48	59113,78	89	M	STATE 17	C6	0,1260	0,0011	0,1625
71	14833,30	88	M	STATE 03	C11	0,0570	0,0010	0,0078
26	11756,34	90	M	STATE 02	C11	0,0488	0,0011	0,0051
180	12234,82	85	F	STATE 15	C6	0,0497	0,0010	0,0046
245	11010,46	84	F	STATE 12	C1	0,0462	0,0009	0,0034

As observações apresentadas na tabela 9 correspondem com os maiores valores para a distância de Cook (D_i). Além de exercerem forte influência sobre os parâmetros estimados, elas possuem alta alavancagem, combinando valores elevados de sinistro pago (`PAID`) e idades avançadas.

E5. Modelo sem Observações Extremas

Para avaliar o impacto das cinco observações extremas reajustamos o modelo Gaussiano Inverso sem elas, esta exclusão tem como finalidade realizar um diagnóstico de robustez.

Tabela 10: Comparação de Estimativas e Erros-Padrão com e sem as Observações Influentes

Parâmetro	Coef. Completo (EP)	Coef. Sem 5 (EP)	Variação (%)	IC 95% Completo	IC 95% Sem 5
Intercepto	7,5211 (0,0220)	7,5103 (0,0213)	-0,14	[7,4780, 7,5642]	[7,4686, 7,5521]
GENDER	0,0090 (0,0357)	0,0161 (0,0347)	78,32	[-0,0610, 0,0790]	[-0,0519, 0,0840]
AGEc	0,0005 (0,0016)	-0,0011 (0,0016)	-319,70	[-0,0027, 0,0037]	[-0,0042, 0,0020]

Os coeficientes e intervalos de confiança indicam que, embora ocorram variações percentuais consideráveis em variáveis específicas (como `AGEc`), os parâmetros mantêm-se na mesma ordem de grandeza e os erros-padrão permanecem estáveis. Podemos dizer que o modelo Gaussiano Inverso apresenta uma robustez satisfatória, uma vez que a remoção das observações influentes não alterou as conclusões globais do ajuste.

Parte F: Validação Cruzada

F1. Construção dos Grupos

Será aplicada uma validação cruzada com dez grupos ($K = 10$), utilizando a mesma partição para todas as especificações avaliadas. Dado que as variáveis `STATE` e `CLASS` possuem um alto número de categorias, gerando 196 estratos distintos na base de dados quando combinadas e que a variável `CLASS`, como já discutido, é um índice da empresa que já considera outras variáveis, os estratos foram feitos buscando manter a proporção de `STATE` igual em todos os grupos.

Tabela 11: Resumo Estatístico dos Dez Grupos de Validação Cruzada

Métrica / Estatística	Grupo 1	Grupo 2	Grupo 3	Grupo 4	Grupo 5	Grupo 6	Grupo 7	Grupo 8	Grupo 9	Grupo 10
Tamanho (n)	678	678	678	677	677	677	677	677	677	677
Média de `PAID`	1867,27	1917,98	1966,74	1897,20	1987,13	1689,20	1790,77	1715,93	1798,90	1898,94
Mediana de `PAID`	999,34	1016,18	1031,01	992,24	1093,36	977,40	965,00	946,38	994,45	1083,25
Média de `AGE`	63,86	63,92	63,98	63,99	63,97	63,67	63,27	63,92	63,56	63,97

A tabela 11 apresenta o resumo descritivo de cada um dos dez grupos construídos. A estratificação garantiu uma distribuição consideravelmente equilibrada e homogênea das variáveis numéricas da amostra e de `STATE`.

F2. Aplicação do Método

Foi usado a ligação log sob o modelo M_1 na aplicação.

Tabela 12: Comparação de Desempenho entre as Famílias de GLM

Família	RMSECV	MAECV	Viés Médio	Correlação
Normal	2647,70	1525,51	0,0539	-0,0405
Gamma	2647,65	1525,48	0,0523	-0,0409
Gaussian_Inverse	2647,63	1525,46	0,0596	-0,0411

A tabela 12 mostra que todas as métricas são muito similares para as 3 famílias, destacando que o viés médio apresentou um valor extremamente próximo de zero e, por outro lado, a correlação global entre os valores observados e previstos também ficou próxima de zero, indicando uma limitada capacidade preditiva.

F3. Considerações Acerca das Métricas

O MAE mede a magnitude média dos erros em uma escala linear, enquanto o RMSE eleva os erros ao quadrado antes de calcular a média e a raiz. Essa operação quadrática atribui um peso maior a desvios grandes, tornando o RMSE muito mais sensível a valores extremos.

A correlação avalia a associação linear, não capturando deslocamentos e diferenças em outras escalas. Vale destacar que a correlação alta também não é um indiciativo único de que o ajuste está bom, é possível que o modelo erre sistematicamente.

F4. Validação Cruzada vs. AIC

Para contrastar a seleção baseada na qualidade de ajuste na amostra (AIC) foi aplicado a validação cruzada para verificar a qualidade do ajuste fora da amostra nas 4 estruturas propostas.

Tabela 13: Desempenho Médio dos Modelos na Validação Cruzada

Modelo	MAE Médio	DP (MAE)	RMSE Médio	DP (RMSE)
M3	**1522,40**	64,66	2623,91	381,89
M4	1523,59	64,34	2625,21	383,68
M1	1525,44	63,15	**2623,15**	377,99
M2	1526,19	62,46	2623,95	379,88

O modelo M_3 apresenta o menor MAE médio e o M_1 o menor RMSE médio. O AIC penaliza o número de parâmetros com base na verossimilhança global, em contrapartida, a validação cruzada avalia diretamente a capacidade preditiva em dados não vistos. As divergências ocorrem porque um modelo com melhor verossimilhança global pode sofrer um leve *overfitting*.

F5. `PAID`: Real vs. Predito

A figura 9 apresenta a dispersão entre os valores observados e as previsões fora da amostra nas escalas original e logarítmica, os pontos em vermelho são os valores mais extremos.

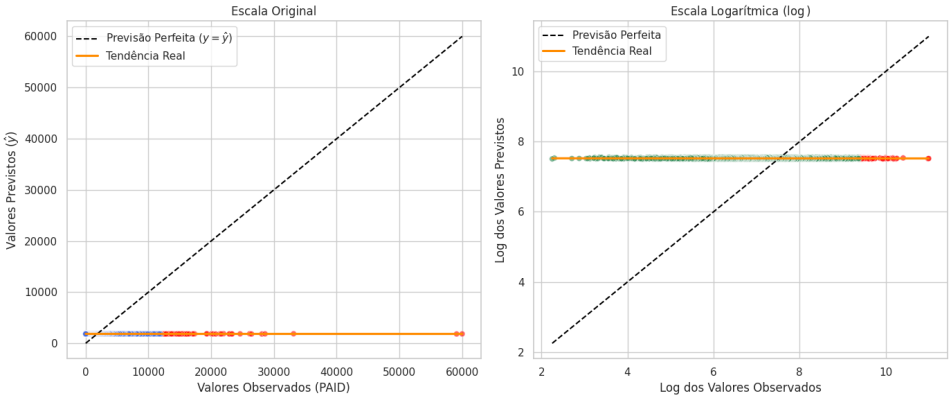


Figura 9: Valores observados vs. previstos nas escalas original e logarítmica.

Os maiores pagamentos são sistematicamente subestimados pelo modelo. Esse comportamente era esperado, pois foi apresentado anteriormente que o valor esperado variável resposta era aproximadamente $\exp(\beta_0)$.

F6. Seleção de Estruturas na Validação Cruzada

A seleção de uma estrutura deve ser feita dentro de cada amostra de treinamento (em cada fold da validação cruzada) porque realizar a seleção em toda a base antes da divisão gera vazamento de informação (*data leakage*). Quando a seleção de variáveis utiliza a amostra completa, o modelo obtem informações do conjunto de teste antes da validação, gerando um *overfitting*.

Parte G: Conclusão

A análise do problema de severidade de sinistros evidencia que os modelos GLM avaliados apresentam grande dificuldade em lidar com os *outliers* da base de dados:

$$\mu_i = E(Y_i|x_i) \approx \exp \hat{\beta}_0 \approx \exp 7,5211 \approx 1.846,597$$

Como esse problema é diretamente ligado as variáveis respostas, as seleções via AIC/BIC foram consideradas adequadas nesse contexto. Os diagnósticos de resíduos e a validação cruzada revelaram uma subestimação sistemática de pagamentos extremos (cauda muito pesada). Esse comportamento acontece por causa da limitação das variáveis preditoras disponíveis. Embora os modelos mantenham um viés médio global próximo de zero e estabilidade em relação a observações influentes, a capacidade preditiva do modelo para valores distantes do intercepto estimado é limitada.

A ausência de informações detalhadas sobre o veículo e o perfil completo do segurado restringe o potencial explicativo do modelo. Para obter um ajuste mais adequado em valores extremos, é necessária a incorporação de covariáveis adicionais em trabalhos futuros.

Ao longo do estudo percebemos que as covariáveis apesar de não terem quase nenhum impacto no valor do sinistro, elas provavelmente possuem grande relação e podem gerar uma análise mais enriquecedora com o número de ocorrência.

As referências utilizadas foram as apresentadas nas instruções do trabalho.